

TN6 – Robot d'exploration Web concurrent


INF2007 – Melissa Moya

1. Implémentation

1.1 Architecture générale

Le programme repose sur neuf fonctions à responsabilité unique, qui propagent les erreurs explicitement plutôt que de paniquer. Cette conception garantit qu'une URL défaillante n'interrompt pas l'exploration des autres, qu'il s'agisse d'un timeout HTTP, d'un code de statut non-200, d'une lecture interrompue ou d'une URL malformée. *CrawlURLs* orchestre l'exploration concurrente en lançant une goroutine par URL, bornée par un sémaphore. La logique principale est extraite dans `run()` pour permettre les tests unitaires sans modifier le comportement en production. La figure 1 illustre le flux d'exécution complet pour une URL, des deux points de décision jusqu'à l'agrégation des résultats par le consommateur unique.

Figure 1 –Flux d'exécution de `crawlURL()`



1.2 Gestion de la concurrence

CrawlURLs combine le patron producteur-consommateur via canal et la synchronisation par mutex, conformément à la consigne du cours. Les goroutines publient leur *CrawlResult* dans un canal bufferisé (*resultsCh*). Après `wg.Wait()` et `close(resultsCh)`, un consommateur unique lit chaque résultat et verrouille un `sync.Mutex` pour mettre à jour *totalWords*, *results* et *errs*, respectant ainsi la synchronisation par mutex.

```

resultsCh := make(chan CrawlResult, len(urls))

// Goroutines productrices :
resultsCh <- crawlURL(targetURL, client, robotsCache, &cacheMu)

// Consommateur unique (après wg.Wait + close) :
for result := range resultsCh {
    mu.Lock()
    if result.Err != nil {
        errs = append(errs, result.Err)
    } else {
        results[result.URL] = result.WordCount
        totalWords += result.WordCount
    }
    mu.Unlock()
}

```

Un *sync.RWMutex* distinct protège le cache *robots.txt* par hôte, où plusieurs goroutines lisent et écrivent simultanément. Le patron de double vérification (lecture partagée, puis écriture exclusive en cas de défaut) évite les requêtes redondantes sans bloquer les lectures concurrentes.

```

cacheMu.RLock()
r, found := cache[host]
cacheMu.RUnlock()

if !found {
    r = fetchRobots(parsed.Scheme, host, client)
    cacheMu.Lock()
    if _, alreadyCached := cache[host]; !alreadyCached {
        cache[host] = r
    } else {
        r = cache[host]
    }
    cacheMu.Unlock()
}

```

Le parallélisme est borné par un sémaphore (canal bufferisé de capacité *maxGoroutines*). Chaque goroutine acquiert un jeton au démarrage et le libère via *defer*.

1.3 Respect de robots.txt

checkRobotsAllowed() délègue à *fetchRobots()*, qui retourne *nil* si le fichier est absent ou inaccessible. L'exploration est autorisée par défaut (RFC 9309). Les résultats sont mis en cache par hôte. Un délai de politesse de 100 ms (*politenessDelay*) limite la fréquence des requêtes en production.

1.4 Comptage des mots

countWordsHTML() analyse le HTML avec le tokeniseur de *golang.org/x/net/html* plutôt qu'avec des expressions régulières, trop fragiles sur du HTML réel (balises incomplètes, attributs complexes, entités). Cette approche extrait uniquement le texte visible et ignore de façon fiable le contenu de *<script>*, *<style>* et *<noscript>*, qui fausserait le décompte. Les entités HTML sont décodées automatiquement.

2. Tests unitaires

Le fichier *crawler_test.go* contient 28 tests unitaires et 3 bancs d'essai, pour une couverture de 100 %. La majorité des tests utilise *httptest.NewServer* afin de supprimer la dépendance au réseau réel et d'assurer la reproductibilité. Un cas spécifique emploie *net.Listen* pour simuler une connexion interrompue (corps annoncé à 1 000 octets, fermeture après 7) et couvrir l'erreur de lecture *io.ReadAll* dans *fetchRobots* et *fetchPage*.

Les tests couvrent les chemins nominaux et les cas limites critiques, notamment le timeout client, la réponse 404 (*http.Client* ne signalant pas les 4xx comme erreurs), l'URL injoignable via 127.0.0.1:1 (port fermé, erreur déterministe sans dépendance DNS) et l'octet nul forçant l'échec de *url.Parse* dans *checkRobotsAllowed*.

La testabilité de *main()* repose sur *mainURLs*, variable de paquet temporairement remplacée par une URL locale puis restaurée avec *defer*. La fonction *run()* est testée dans trois scénarios (succès, erreurs seules, résultats mixtes), ce qui couvre ses deux branches d'affichage.

3. Analyse des performances

3.1 Protocole et résultats

Les données de test sont générées hors de la boucle *b.N*, *b.ReportAllocs()* confirme l'absence d'allocations parasites pendant la mesure, et *b.ResetTimer()* est utilisé dans les trois benchmarks pour exclure le temps d'initialisation (création du serveur et des URLs). Le délai de politesse est désactivé (*politenessDelay* = 0) afin d'isoler l'effet du parallélisme. Les benchmarks ont été exécutés avec *go test -bench=Benchmark -benchmem -run=^\$ -count=6* sur un Intel i5-10300H à 2,50 GHz (Windows/amd64).


Deux scénarios isolent des contentions différentes. *BenchmarkCrawlGoroutines* compare 1, 2, 4 et 8 goroutines sur 8 URLs vers un serveur unique (contention côté serveur), tandis que *BenchmarkCrawlGoroutinesMultiServer* répète la même comparaison avec 8 serveurs distincts pour mesurer le parallélisme effectif. *BenchmarkCountWordsHTML* évalue séparément le coût du tokeniseur HTML sur une page d'environ 1 900 mots.

Tableau 2 – Résultats des benchmarks de crawl (benchstat, count=6)

Configuration	Temps (ms)	Variance	Accélération vs 1G
Serveur unique, 1 goroutine	1,91	± 2 %	1,00×
Serveur unique, 2 goroutines	1,18	± 7 %	1,62×
Serveur unique, 4 goroutines	3,09	± 196 %	0,62×
Serveur unique, 8 goroutines	10,80	± 6 %	0,18×
Multi-serveurs, 1 goroutine	3,14	± 7 %	1,00×
Multi-serveurs, 2 goroutines	1,72	± 5 %	1,82×
Multi-serveurs, 4 goroutines	0,95	± 2 %	3,30×
Multi-serveurs, 8 goroutines	0,71	± 2 %	4,44×

La figure 2 illustre visuellement le croisement des deux courbes à 2 goroutines, point à partir duquel les comportements divergent selon la source de contention.

Figure 2 – Temps d'exécution selon le nombre de goroutines



3.2 Analyse

Avec un serveur unique, les performances se dégradent au-delà de 2 goroutines. La forte variance à 4 goroutines ($\pm 196\%$) et la régression à 8 goroutines s'expliquent surtout par la contention dans le serveur de test *httptest.NewServer*, qui convertit l'excès de parallélisme en surcoût de coordination. C'est principalement un artefact de banc d'essai, mais cohérent avec le cas réel où plusieurs URLs partagent un même hôte.

Les données brutes à 4 goroutines confirment cette instabilité. Trois exécutions autour de 1,78 ms précèdent 4,4 ms, 8,6 ms et 9,1 ms, vraisemblablement sous interférence de l'ordonnanceur Windows. La médiane benchstat (3,09 ms) reste donc peu représentative pour cette configuration.

En scénario multi-hôtes (8 serveurs), la performance passe de 3,14 ms à 0,71 ms, soit $4,44\times$ d'accélération, avec une variance faible ($\pm 2\%$ à 4 et 8 goroutines). Le rendement reste décroissant, comme attendu quand la part séquentielle devient dominante.

BenchmarkCountWordsHTML ($346\ \mu\text{s} \pm 35\%$, 48 Ko, 204 allocations) montre que le parsing HTML n'est pas le goulot principal. La limite de performance du crawler demeure la latence réseau, ce que confirme le gain $4,44\times$ en multi-hôtes.

4. Défis et optimisations

Le cache robots.txt (§1.2) et la variable politenessDelay (§1.3) ont résolu deux défis liés. Le cache élimine les requêtes redondantes vers /robots.txt et politenessDelay isole le parallélisme dans les benchmarks sans modifier le comportement en production.

Pour atteindre 100 % de couverture, certains cas ont nécessité des simulations hors *httptest.NewServer*. Ces simulations comprennent une connexion TCP interrompue via *net.Listen* pour forcer une erreur de lecture, un octet nul pour faire échouer *url.Parse* et la substitution de *mainURLs* pour tester *main()* sans réseau externe.

Avec plus de temps, les benchmarks auraient été relancés sur machine dédiée avec *-benchtime=5s*. Les variances observées ($\pm 196\%$ à 4 goroutines, $\pm 35\%$ pour *BenchmarkCountWordsHTML*) indiquent une interférence du planificateur Windows. Des mesures plus stables auraient mieux quantifié le rendement décroissant au-delà de 4 goroutines.

5. Conclusion

Ce projet démontre comment robustesse, concurrence structurée et mesure rigoureuse se combinent en un crawler fiable. Il atteint $4,44\times$ d'accélération en multi-hôtes, 100 % de couverture sur 28 tests et le respect de robots.txt avec cache par hôte et délai de politesse configurable.

6. Bibliographie

- Manuel INF2007, chapitres 1, 6 et 8.
- Documentation Go : <https://pkg.go.dev/net/http>, <https://pkg.go.dev/sync>
- RFC 9309 — Protocole d'exclusion des robots : <https://www.rfc-editor.org/rfc/rfc9309>
- Bibliothèque robotstxt : <https://github.com/temoto/robotstxt>
- Bibliothèque HTML : <https://pkg.go.dev/golang.org/x/net/html>