


TN6 – Robot d'exploration Web concurrent

1. Implémentation

1.1 Architecture générale

Le programme repose sur neuf fonctions à responsabilité unique, qui propagent les erreurs explicitement plutôt que de paniquer. Cette conception garantit qu'une URL défaillante n'interrompt pas l'exploration des autres, qu'il s'agisse d'un timeout HTTP, d'un code de statut non-200, d'une lecture interrompue ou d'une URL malformée. CrawlURLs orchestre l'exploration concurrente en lançant une goroutine par URL, bornée par un sémaphore. La logique principale est extraite dans run() pour permettre les tests unitaires sans modifier le comportement en production. La figure 1 illustre le flux d'exécution complet pour une URL, des deux points de décision jusqu'à l'agrégation des résultats par le consommateur unique.

Figure 1 –Flux d'exécution de crawlURL()



1.2 Gestion de la concurrence

CrawlURLs applique un patron producteur-consommateur: les goroutines de crawl publient des CrawlResult dans un canal bufferisé, puis un consommateur unique agrège résultats, totalWords et erreurs. Comme une seule goroutine écrit ces structures, cette partie est intrinsèquement thread-safe et ne nécessite pas de mutex.

```

resultsCh := make(chan CrawlResult, len(urls))

// Goroutine productrice :
resultsCh <- crawlURL(targetURL, client, robotsCache, &cacheMu)

// Consommateur unique (après wg.Wait + close) :
for result := range resultsCh {
    mu.Lock()
    // mise à jour de results, totalWords, errs
    mu.Unlock()
}

```

Un `sync.RWMutex` distinct protège le cache `robots.txt` par hôte. Le schéma de double vérification (lecture partagée, puis écriture exclusive en cas de défaut) évite les requêtes redondantes sans bloquer les lectures concurrentes.

```

cacheMu.RLock()
r, found := cache[host]
cacheMu.RUnlock()

if !found {
    r = fetchRobots(parsed.Scheme, host, client)
    cacheMu.Lock()
    if _, alreadyCached := cache[host]; !alreadyCached {
        cache[host] = r
    } else {
        r = cache[host]
    }
    cacheMu.Unlock()
}

```

Le parallélisme est borné par un sémaphore (canal bufferisé de capacité `maxGoroutines`): chaque goroutine acquiert un jeton au démarrage et le libère via `defer`. Cette borne limite la pression sur les ressources locales et sur les serveurs distants.

```

semaphore := make(chan struct{}, maxGoroutines)
// ...
semaphore <- struct{}{} // acquiert le jeton (bloque si maxGoroutines
actives)
defer func() { <-semaphore }() // libère toujours, même en cas de panique
    cacheMu.Unlock()
}

```

1.3 Respect de robots.txt

`checkRobotsAllowed()` délègue la récupération à `fetchRobots()`, qui retourne `nil` si le fichier est absent ou inaccessible, autorisant l'exploration par défaut conformément à la convention standard. Les résultats sont mis en cache par hôte pour éviter des requêtes répétées vers `/robots.txt`.

Un délai de politesse de 100 ms (`politenessDelay`) est appliqué avant chaque requête principale pour limiter la fréquence des accès aux serveurs explorés. Il est désactivé dans les bancs d'essai pour isoler l'effet réel du parallélisme.

1.4 Comptage des mots

`countWordsHTML()` analyse le HTML avec le tokeniseur de golang.org/x/net/html plutôt qu'avec des expressions régulières, trop fragiles sur du HTML réel (balises incomplètes, attributs complexes, entités). Cette approche extrait uniquement le texte visible et ignore de façon fiable le contenu de

<script>, <style> et <noscript>, qui fausserait le décompte. Les entités HTML sont décodées automatiquement.

2. Tests unitaires

Le fichier [crawler test.go](https://github.com/GoogleCloudPlatform/cloudsql-proxy/blob/master/test.go) contient 28 tests unitaires et 3 bancs d'essai, pour une couverture de 100 %. La majorité des tests utilise `httptest.NewServer` afin de supprimer la dépendance au réseau réel et d'assurer la reproductibilité ; un cas spécifique emploie `net.Listen` pour simuler une connexion interrompue (corps annoncé à 1 000 octets, fermeture après 7) et couvrir l'erreur de lecture `io.ReadAll` dans `fetchRobots`.

Les tests couvrent les chemins nominaux et les cas limites critiques : timeout client, réponse 404 (`http.Client` ne signalant pas les 4xx comme erreurs), et URL invalide via octet nul pour forcer l'échec de `url.Parse` dans `checkRobotsAllowed`.

La testabilité de `main()` repose sur `mainURLs`, variable de paquet temporairement remplacée par une URL locale puis restaurée avec `defer`. La fonction `run()` est testée dans trois scénarios (succès, erreurs seules, résultats mixtes), ce qui couvre ses deux branches d'affichage.

3. Analyse des performances

3.1 Protocole et résultats

Les données de test sont préparées hors de la boucle `b.N` ; `b.ReportAllocs` confirme l'absence d'allocations parasites pendant la mesure, et `b.ResetTimer` est utilisé dans `BenchmarkCrawlGoroutinesMultiServer` et `BenchmarkCountWordsHTML` pour exclure l'initialisation. Le délai de politesse est désactivé (`politenessDelay = 0`) afin d'isoler l'effet du parallélisme. Les benchmarks ont été exécutés avec `go test -bench=Benchmark -benchmem -run=^$ -count=6` sur un Intel i5-10300H à 2,50 GHz (Windows/amd64).


Deux scénarios isolent des contentions différentes : `BenchmarkCrawlGoroutines` compare 1, 2, 4 et 8 goroutines sur 8 URLs vers un serveur unique (contention côté serveur), tandis que `BenchmarkCrawlGoroutinesMultiServer` répète la même comparaison avec 8 serveurs distincts pour mesurer le parallélisme effectif. `BenchmarkCountWordsHTML` évalue séparément le coût du tokeniseur HTML sur une page d'environ 1 900 mots.

Tableau 2 – Résultats des benchmarks de crawl (benchstat, count=6)

| Configuration | Temps (ms) | Variance | Accélération vs 1G |
|------------------------------|------------|----------|--------------------|
| Serveur unique, 1 goroutine | 1,91 | ± 2 % | 1,00× |
| Serveur unique, 2 goroutines | 1,18 | ± 7 % | 1,62× |
| Serveur unique, 4 goroutines | 3,09 | ± 196 % | 0,62× |
| Serveur unique, 8 goroutines | 10,80 | ± 6 % | 0,18× |
| Multi-serveurs, 1 goroutine | 3,14 | ± 7 % | 1,00× |
| Multi-serveurs, 2 goroutines | 1,72 | ± 5 % | 1,82× |
| Multi-serveurs, 4 goroutines | 0,95 | ± 2 % | 3,30× |
| Multi-serveurs, 8 goroutines | 0,71 | ± 2 % | 4,44× |

La figure 2 illustre visuellement le croisement des deux courbes à 2 goroutines, point à partir duquel les comportements divergent selon la source de contention.

Figure 2 – Temps d'exécution selon le nombre de goroutines



3.2 Analyse

Avec un serveur unique, les performances se dégradent au-delà de 2 goroutines. La forte variance à 4 goroutines ($\pm 196\%$) et la régression à 8 goroutines s'expliquent surtout par la contention dans le serveur de test `httpstest.NewServer`, qui convertit l'excès de parallélisme en surcoût de coordination. C'est principalement un artefact de banc d'essai, mais cohérent avec le cas réel où plusieurs URLs partagent un même hôte.

Les données brutes à 4 goroutines confirment cette instabilité: trois exécutions autour de 1,78 ms, puis 4,4 ms, 8,6 ms et 9,1 ms, vraisemblablement sous interférence de l'ordonnanceur Windows. La médiane benchstat (3,09 ms) reste donc peu représentative pour cette configuration.

En scénario multi-hôtes (8 serveurs), la performance passe de 3,14 ms à 0,71 ms, soit $4,44\times$ d'accélération, avec une variance faible ($\pm 2\%$ à 4 et 8 goroutines). Le rendement reste décroissant, comme attendu quand la part séquentielle devient dominante.

`BenchmarkCountWordsHTML` ($346\ \mu s \pm 35\%$, 48 Ko, 204 allocations) montre que le parsing HTML n'est pas le goulot principal; la limite de performance du crawler demeure la latence réseau, ce que confirme le gain $4,44\times$ en multi-hôtes.

4. Défis et optimisations

Sans cache de `robots.txt`, chaque URL aurait refait une requête vers `/robots.txt`. Un cache par hôte protégé par `sync.RWMutex`, avec double vérification (lecture partagée puis verrou exclusif en cas de défaut), supprime ces accès redondants sans bloquer les lectures concurrentes.

Le délai de politesse de 100 ms, nécessaire en production, fausserait les benchmarks ; `politenessDelay` est donc exposé comme variable de paquet pour être désactivé en test sans changer le comportement réel.

Pour atteindre 100 % de couverture, certains cas ont nécessité des simulations hors `httpstest.NewServer` : connexion TCP interrompue via `net.Listen` pour forcer une erreur de lecture, octet nul pour faire échouer `url.Parse`, et substitution de `mainURLs` pour tester `main()` sans réseau externe.

Avec plus de temps, les benchmarks auraient été relancés sur machine dédiée avec `-benchtime=5s`. Les variances observées ($\pm 196\%$ à 4 goroutines, $\pm 35\%$ pour `BenchmarkCountWordsHTML`) indiquent une interférence du planificateur Windows ; des mesures plus stables auraient mieux quantifié le rendement décroissant au-delà de 4 goroutines.

5. Conclusion

Ce projet démontre comment la robustesse, la concurrence structurée et la mesure rigoureuse se combinent pour produire un crawler fiable et performant. Un `sync.Mutex` protège l'agrégation du compteur global `totalWords` contre les accès concurrents, le sémaphore bufferisé contrôle le degré de parallélisme et les 28 tests unitaires atteignent une couverture de 100 %. Les benchmarks confirment une accélération de 4,44× en scénario multi-hôtes et un parsing HTML de 346 µs pour 48 Ko alloués. La conformité à `robots.txt` avec cache par hôte et délai de politesse configurable complète une implémentation correcte, performante et éthiquement responsable.